

Anexos técnicos · Pipeline multilenguaje GeoAI para el monitoreo del manglar en la Ciénaga Grande de Santa Marta (2013–2025)

Documento complementario del informe final

Lina María Quintero Fonseca

2026-05-25

Presentación

Este documento complementario reúne cinco anexos del proyecto Pipeline multilenguaje GeoAI para el monitoreo del manglar en la Ciénaga Grande de Santa Marta (2013–2025). Cada anexo desarrolla material de soporte que sustenta las decisiones metodológicas, la reproducibilidad y la trazabilidad de los resultados reportados en el informe principal (informe_final_revisado.docx):

- **Anexo A** documenta la configuración del entorno Docker `sig_unal v1.11` con los paquetes adicionales de Python, R y Julia.
- **Anexo B** describe la estructura del repositorio GitHub con la serie vigente y la legacy de notebooks.
- **Anexo C** explica la discrepancia metodológica en el conteo de parches entre las implementaciones de Julia y Python.
- **Anexo E** contiene los fragmentos de código que materializan cada fase del pipeline.
- **Anexo F** reúne las tablas de detalle.

(Nota: el Anexo D se conserva sin contenido para mantener la correspondencia con versiones previas y evitar modificar las referencias internas.)

Anexo A: Configuración del entorno Docker

El proyecto se ejecuta sobre el contenedor Docker `sig_unal v1.11` proporcionado para la asignatura, con las siguientes modificaciones:

```
# Librerías Python adicionales instaladas
pip install earthengine-api geemap segment-geospatial leafmap
pip install rasterio geopandas xarray shapely folium rasterstats
pip install matplotlib pandas numpy scikit-learn contextily
pip install cdsapi netCDF4 # descarga ERA5-Land desde CDS

# Autenticación Google Earth Engine
earthengine authenticate --auth_mode=notebook

# Autenticación Climate Data Store (ECMWF) – para ERA5-Land
# 1) Crear cuenta en https://cds.climate.copernicus.eu/
# 2) Aceptar términos del conjunto de datos reanalysis-era5-land-monthly-means
# 3) Crear archivo ~/.cdsapirc con la URL y la API key personales

# Paquetes R adicionales
install.packages(c("bfast", "terra", "sf", "ggplot2", "tseries",
                  "stars", "dplyr", "tidyr", "readr", "stringr"))
```

```
# Paquetes Julia adicionales
using Pkg
Pkg.add(["GeoJSON", "DataFrames", "CSV", "Statistics"])
```

La autenticación con GEE se realiza mediante el flujo gcloud auth application-default login con quota project configurado, que genera credenciales almacenadas en ~/.config/gcloud/application_default_credentials.json. El contenedor requiere un mínimo de 8 GB de RAM asignados en Docker Desktop para ejecutar SamGeo con el backbone vit_b; con vit_h se requieren al menos 12 GB. Las composiciones RGB se remuestran de 10 a 30 metros antes de la segmentación para reducir el consumo de memoria.

Anexo B: Estructura del repositorio GitHub

El repositorio público está disponible en [bajo licencia MIT](https://github.com/LinaQuinteroF/proyecto-cgsm). La versión anterior del proyecto (línea base marzo 2026 sobre AOI preliminar de 5.073 km²) permanece archivada en [para fines de comparación histórica](https://github.com/LinaQuinteroF/proyecto-cgsm). <https://github.com/LinaQuinteroF/proyecto-cgsm>

```
proyecto-cgsm-curso/├─ notebooks/          30 notebooks: 23 serie principal + 7 legacy (traza
bilidad)│          orden de ejecución: 01 → 02 → 02b → 03_acotado →│
          04_acotado → 04b_acotado → 05_acotado → 06b → 07 → 08 →│          09b → 1
0 → 11 → 11b → 12 → 12b → 12c → 13 → 14├─ src/│          ├─ python/          utils.py (9377 + DE-9I
M), aoi_acotado.py, build_cubos.py,│          │          make_dashboard_html.py, alertas_man
glar.py, merge_cubo.py│          └─ R/          03_bfast_ndvi.R, 05_stars_cubo.R, 06_bfast_mangl
ar_unificado.R,│          │          08_correlacion_trilingual.R│          └─ julia/          04_fra
gmentacion.jl (4326 legacy + 9377 vigente),│          05_correlacion_trilingual.j
l├─ data/│          ├─ raw/          AOI preliminar y acotado, RUNAP SFF + VPI, INVEMAR GBIF,│
│          │          IDEAM El Banco / Ganadería Caribe│          └─ processed/│          └─ cubo/          3
datacubes NetCDF CF-1.8 (40 / 275 / 119 MB)│          └─ samgeo/          máscaras y GeoJSON por per
iodo├─ outputs/│          ├─ tables/          47 CSV con resultados numéricos│          └─ figures/          3
5 PNG (mapas, series, correlaciones, alertas)│          └─ maps/          dashboard_CGSM_final.html
└─ docs/          informe_final.{qmd,html,pdf}, informe_anexos.{qmd,html,pdf}
```

La serie vigente (notebooks 01–12 + 02b, 04b/c_acotado, 09b, 11b, 12b/c, 14) reproduce las cifras del cuerpo del informe sobre el AOI acotado de 835 km². La serie legacy (03, 04, 04b, 05, 06, 09 sin sufijo _acotado) opera sobre el AOI preliminar de 5.073 km² y se conserva sólo por trazabilidad histórica; no sostiene ninguna conclusión del informe. La guía de ejecución por etapa con dependencias entre notebooks se documenta en notebooks/README.md. Las composiciones trimestrales y anuales en GeoTIFF y los NetCDF de mayor tamaño no se versionan por restricciones de tamaño de GitHub: se regeneran ejecutando los notebooks en orden secuencial con acceso autenticado a GEE.

Anexo C: Nota metodológica sobre el conteo de parches (Julia vs Python)

La diferencia entre los conteos de parches en Julia y Python se debe al tratamiento geométrico de polígonos con anillos interiores y geometrías multipartes. Mientras geopandas calcula el área neta descontando huecos internos, la implementación en Julia se utilizó para caracterizar unidades geométricas de paisaje y métricas de conectividad. Por esta razón, el informe distingue explícitamente entre conteos derivados de Julia (Tabla 5 del cuerpo del informe) para métricas de forma y aislamiento, y salidas geopandas (en outputs/tables/parches_geopandas.csv del repositorio) para indicadores de superficie efectiva.

Anexo E: Fragmentos abreviados de código

Para mantener el cuerpo del informe centrado en la interpretación de resultados, los fragmentos de código que materializan cada fase del pipeline se documentan en este anexo, organizados temáticamente en cuatro apartados que reproducen el orden lógico de la cadena de procesamiento: datacube y series temporales (E.1), reproyección y topología sobre parches segmentados (E.2), forzamiento climático y detección SAR (E.3), y métricas de fragmentación del paisaje en Julia (E.4). Los conceptos técnicos invocados aquí, datacube, z-score, bfast, SamGeo, predicado DE-9IM, Random Forest, backscatter SAR, dispersión de doble rebote, F1-score, se introducen y explican funcionalmente en el cuerpo del `informe_final_revisado.docx`; este anexo se concentra en la implementación operativa y supone que el lector conoce ya su significado conceptual.

Nota: los fragmentos incluidos son extractos abreviados para documentación metodológica. La versión ejecutable completa se encuentra en los notebooks y scripts del repositorio.

E.1 Datacube multitemporal y series de tiempo

E.1.a Lectura perezosa del datacube NetCDF con xarray

El datacube trimestral materializado como NetCDF CF-1.8 se abre con evaluación perezosa mediante `xarray.open_dataset` con argumento `chunks`, de modo que las operaciones de selección y reducción se planifican como un grafo de cómputo dask y solo se materializan los píxeles necesarios al invocar `.compute()`. Este patrón resulta indispensable para los tres archivos del proyecto (40 MB, 275 MB y 119 MB) cuando se trabaja sobre la totalidad de las 31 láminas trimestrales sin saturar la memoria del contenedor.

```
import xarray as xr

ds = xr.open_dataset('data/processed/cubo/cgsm_datacube_trimestral.nc',
                    chunks={'time': 1, 'x': 512, 'y': 512})

# Atributos CF-1.8: Conventions, institution, creator_name, crs_origen, ...
# Acceso perezoso por chunks; .compute() materializa cuando es necesario
ndvi_serie = ds['reflectance'].sel(band_idx='NDVI').median(dim=['x', 'y']).compute()
```

E.1.b Z-scores y detección de anomalías NDVI en Python

Sobre la serie combinada Landsat 8 + Sentinel-2 se calcula el z-score temporal por estación mediante `groupby().transform()`, lo que permite identificar anomalías pronunciadas como aquellas con `z_score < -2`. El resultado alimenta tanto la tabla de eventos de mortandad como la lógica del módulo de alertas tempranas.

```
# Z-scores y detección de anomalías por estación
df['z_score'] = df.groupby('estación')['ndvi'].transform(
    lambda x: (x - x.mean()) / x.std())
anomalias = df[df['z_score'] < -2].sort_values('z_score')
```

E.1.c Cubo stars en R y extracción sobre estaciones INVEMAR

Como contraparte local del flujo Python+GEE de la Fase 2, los TIFs trimestrales descargados desde GEE se ensamblan en R como un cubo `stars` proxy —con evaluación perezosa hasta que `st_extract` materializa los valores sobre las ocho estaciones INVEMAR—. La salida `series_temporales_stars.csv` se contrasta contra `serie_temporal_ndvi_definitiva.csv` para sostener la validación cruzada multilingüe Python ↔ R reportada en la sección homónima.

```
library(stars); library(sf); library(dplyr)
tifs <- list.files("data/processed/s2", pattern = "NDVI.*\\.tif$", full.names = TRUE)
fechas <- as.Date(stringr::str_match(basename(tifs), "(\\d{4})_Q(\\d)")[, c(2, 3)])
cubo <- read_stars(tifs, along = list(time = fechas), proxy = TRUE)
serie <- st_extract(cubo, st_transform(estaciones_sf, st_crs(cubo)))
```

E.1.d Construcción de la colección Sentinel-2 SR Harmonized y cálculo de índices

La colección óptica del proyecto se arma en Google Earth Engine filtrando `COPERNICUS/S2_SR_HARMONIZED` sobre el AOI, aplicando una máscara de nubes basada en la banda QA60 y añadiendo en una sola pasada los tres índices espectrales que sostienen el resto del pipeline —NDVI, NDWI y CMRI—.

```
# Construir coleccion S2 SR Harmonized y agregar tres indices espectrales
def add_indices(image):
    ndvi = image.normalizedDifference(['B8', 'B4']).rename('NDVI')
    ndwi = image.normalizedDifference(['B3', 'B8']).rename('NDWI')
    cmri = ndvi.subtract(ndwi).rename('CMRI')
    return image.addBands([ndvi, ndwi, cmri])

s2 = (ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED')
      .filterBounds(aoi)
      .filterDate('2018-01-01', '2025-12-31')
      .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 20))
      .map(mask_s2_clouds)
      .map(add_indices))
```

E.1.e Detección de quiebres estructurales con `bfast` en R

Sobre las series mensuales combinadas Landsat 8 + Sentinel-2 (929 observaciones) se aplica el algoritmo `bfast::bfast` con `h = 0,10` y descomposición armónica en dos iteraciones, lo que arroja los quiebres asociados a El Niño 2015–2016, La Niña 2020–2021 y El Niño 2023–2024.

```
library(bfast)
serie <- read.csv("outputs/tables/serie_temporal_ndvi_combinada.csv")
ts_est <- ts(subset(serie, estación == "Cano_Palos")$ndvi,
             start = c(2013, 1), frequency = 12)
fit <- bfast(ts_est, h = 0.10, season = "harmonic", max.iter = 2)
plot(fit) # quiebres 2016 (El Nino), 2020 (La Nina), 2023-24 (El Nino)
```

E.1.f Monitor near-real-time con `bfastmonitor` en R

Sobre las mismas series mensuales combinadas Landsat 8 + Sentinel-2 se aplica `bfast::bfastmonitor` con una ventana histórica 2013–2019 y un periodo de monitoreo 2020–2025. El modelo ajusta una descomposición armónica con `harmon` de orden 3 sobre la ventana histórica, considerada estable tras la rehabilitación hidráulica de canales (1996–1998), y evalúa el periodo de monitoreo en busca de breakpoints al nivel de significancia $p < 0,05$. La salida `outputs/tables/bfastmonitor_estaciones.csv` contiene, por estación, la fecha del breakpoint detectado, su magnitud y el estado del monitor a la fecha de corte, y alimenta directamente la lógica del semáforo descrita en la sección homónima del cuerpo del informe.

```
library(bfast)
serie <- read.csv("outputs/tables/serie_temporal_ndvi_combinada.csv")
```

```
# Por estación, ajustar bfastmonitor con history 2013-2019 / monitor 2020-2025
resultados <- lapply(unique(serie$estación), function(est) {
  ts_est <- ts(subset(serie, estación == est)$ndvi,
    start = c(2013, 1), frequency = 12)
  mon <- bfastmonitor(ts_est,
    start = c(2020, 1),
    formula = response ~ harmon,
    order = 3,
    level = 0.05)
  data.frame(estación = est,
    breakpoint = as.character(time(mon$breakpoint)),
    magnitud = mon$magnitude)
})

write.csv(do.call(rbind, resultados),
  "outputs/tables/bfastmonitor_estaciones.csv", row.names = FALSE)
```

E.2 Reproyección al sistema oficial colombiano y topología DE-9IM

E.2.a Lectura perezosa del raster, reproyección a EPSG:9377 y predicados topológicos

Los rasters de máscara producidos por SamGeo se inspeccionan abriendo el archivo con `rasterio.open()` para extraer dimensiones, CRS, resolución y valor de NoData sin materializar la grilla en memoria; los GeoJSON resultantes se re proyectan a MAGNA-SIRGAS Origen Nacional (EPSG:9377) —estándar oficial del IGAC desde la Resolución 471 de 2020— y sobre los parches re proyectados se aplican los predicados topológicos `intersects` con la frontera del AOI y `contains` con los puntos de muestreo INVEMAR, en ambos casos delegando en GEOS los mismos cálculos que sustentan PostGIS y JTS.

```
from src.python.utils import (
    raster_metadata, vector_to_9377, area_ha_9377,
    parches_borde, parches_con_punto, EPSG_NACIONAL,
)

# Inspeccion lazy del raster: metadatos sin cargar la grilla
meta = raster_metadata('data/processed/samgeo/mask_actual.tif')

# Reproyeccion al sistema oficial colombiano MAGNA-SIRGAS
vector_to_9377('data/processed/samgeo/manglar_actual.geojson',
  'data/processed/samgeo/manglar_actual_9377.geojson')

# Predicados topológicos DE-9IM sobre los parches re proyectados
gdf = area_ha_9377(gpd.read_file('data/processed/samgeo/manglar_actual_9377.geojson'))
gdf = parches_borde(gdf, aoi) # intersects con la frontera
gdf = parches_con_punto(gdf, estaciones) # contains con los puntos INVEMAR
```

E.2.b Segmentación guiada por prompts con SamGeo vit_b y vectorización por periodo

La segmentación automática de las composiciones RGB de los tres periodos de referencia se ejecuta con el backbone `vit_b` de SamGeo —versión adaptada al límite de memoria del contenedor `sig_unal v1.11`— produciendo una máscara raster por periodo que se vectoriza a GeoJSON para el posterior filtrado por área y cálculo de métricas de fragmentación.

```
from samgeo import SamGeo

# Modelo base vit_b para ajustarse a la RAM del contenedor
sam = SamGeo(model_type='vit_b', automatic=True)

for periodo in ['degradación', 'recuperación', 'actual']:
    rgb = f'{res_dir}/CGSM_RGB_{periodo}_30m.tif'
    mask = f'{out_dir}/mask_{periodo}.tif'
    poly = f'{out_dir}/manglar_{periodo}.geojson'
```

```
sam.generate(rgb, output=mask)      # raster binario
sam.tiff_to_vector(mask, poly)     # parches vectoriales
```

E.3 Forzamiento climático y detección SAR

E.3.a Descarga ERA5-Land mediante cdsapi y cálculo de anomalías mensuales

La descarga del reanálisis ERA5-Land del ECMWF se realiza con cdsapi directamente desde el Climate Data Store, solicitando precipitación total y temperatura a dos metros sobre un bounding box que envuelve la CGSM con buffer; los datos se reciben en NetCDF con convenciones CF y se cargan con xarray.open_dataset(chunks=...) aplicando un patrón perezoso, calculando la climatología mensual y la anomalía respecto a ella para los rezagos cero a tres meses.

```
import cdsapi, xarray as xr

c = cdsapi.Client()
c.retrieve('reanalysis-era5-land-monthly-means', {
    'product_type': 'monthly_averaged_reanalysis',
    'variable': ['total_precipitation', '2m_temperature'],
    'year': [str(y) for y in range(2018, 2026)],
    'month': [f'{m:02d}' for m in range(1, 13)],
    'time': '00:00',
    'area': [11.20, -75.05, 10.30, -74.05],
    'format': 'netcdf'
}, 'data/raw/era5_land_cgsm_monthly.nc')

ds = xr.open_dataset('data/raw/era5_land_cgsm_monthly.nc', chunks={'time': 12})
anom = ds.groupby('time.month') - ds.groupby('time.month').mean('time')
```

E.3.b Detección de inundación Sentinel-1 SAR para el evento de septiembre 2020

Para el evento de septiembre de 2020 se realizó una detección de inundación mediante Sentinel-1 SAR, banda VH y modo IW, comparando el backscatter medio del periodo seco de referencia, enero-marzo de 2020, con el periodo de inundación, septiembre-octubre de 2020. En el código, la diferencia se definió como SAR diff = seco – inundación. Bajo esta convención, se identificó agua abierta cuando SAR diff fue superior a +3 dB, asociada con disminución del backscatter durante la inundación por reflexión especular, y manglar inundado bajo dosel cuando SAR diff fue inferior a -2 dB, asociado con aumento del backscatter durante la inundación por dispersión de doble rebote agua-tronco.

```
s1_dry = ee.ImageCollection('COPERNICUS/S1_GRD') \
    .filterDate('2020-01-01', '2020-03-31').select('VH').median()
s1_flood = ee.ImageCollection('COPERNICUS/S1_GRD') \
    .filterDate('2020-09-01', '2020-10-31').select('VH').median()
sar_diff = s1_dry.subtract(s1_flood)
flood_open = sar_diff.gt(3).selfMask() # agua abierta
flood_canopy = sar_diff.lt(-2).selfMask() # bajo dosel
```

E.4 Métricas de fragmentación del paisaje (Julia)

E.4.a Cálculo de área (shoelace), MSI y NND sobre parches en EPSG:9377

La función `compute_metrics` agrega los parches segmentados de cada periodo, calcula el área de cada polígono mediante la fórmula del cordón sobre coordenadas en metros (EPSG:9377), deriva el índice de forma medio MSI = perímetro / $\sqrt{(\pi \cdot \text{área})}$ y la distancia al vecino más cercano NND, y devuelve un `DataFrame` con la fila resumen del periodo. Esta función se invoca tres veces —una por periodo de referencia— y los resultados alimentan la tabla de fragmentación reportada en la sección homónima del cuerpo del informe.

```
using GeoJSON, DataFrames, Statistics

function compute_metrics(periodo, base_dir)
    path = joinpath(base_dir, "manglar_$(periodo)_9377.geojson")
```

```
parches = GeoJSON.read(read(path, String))

# Area por formula del cordon (shoelace) y perímetro en metros
áreas = [shoelace_area(p) for p in parches]
perim = [polygon_perimeter(p) for p in parches]
msi = perim ./ sqrt(pi .* áreas)          # índice de forma medio
nnd = nearest_neighbor_distances(parches)  # km al vecino más cercano

return DataFrame(
    periodo = periodo,
    n_parches = length(parches),
    area_total = sum(áreas) / 1e4,          # hectáreas
    area_media = mean(áreas) / 1e4,
    msi_mean = mean(msi),
    nnd_mean = mean(nnd) / 1e3,
)
end
```

Anexo F: Tablas detalladas

Para mantener el cuerpo del informe centrado en la narrativa de los hallazgos, dos tablas de detalle metodológico se reubican en este anexo: el cruce estación por estación entre la señal SAR de septiembre 2020, la anomalía NDVI y la frecuencia de inundación histórica de la Global Flood Database (referida en la sección de Validación con datos NASA), y las nueve transiciones de superficie del JRC Global Surface Water 1984–2021 (referida en la sección de Dinámica hídrica).

Nota de homologación de estaciones complementarias. En la serie legacy desarrollada sobre el AOI preliminar de 5.073 km², dos estaciones complementarias del Complejo de Pajarales fueron registradas con la nomenclatura CP Pajarales y VIPIS. Durante la depuración metodológica hacia el AOI acotado de 835,3 km², estas estaciones fueron homologadas y reubicadas sobre cobertura de manglar denso verificada mediante NDVI > 0,4 en composiciones Sentinel-2 de 2024. En la nomenclatura vigente del informe principal, CP Pajarales corresponde a CP Aguas Negras y VIPIS corresponde a CP Luna. Esta homologación no representa únicamente un cambio de etiqueta, sino también un ajuste espacial de coordenadas para garantizar consistencia con el AOI acotado y con la cobertura efectiva de manglar analizada. Las tablas de este anexo reportan la nomenclatura vigente y conservan la equivalencia legacy únicamente como nota de trazabilidad.

Nombre legacy	Nombre vigente	Observación
CP Pajarales	CP Aguas Negras	Reubicada hacia manglar denso del sector Aguas Negras, dentro del Complejo de Pajarales
VIPIS	CP Luna	Reubicada hacia manglar denso del sector CP Luna, dentro del Complejo de Pajarales

F.1 Cruce SAR + NDVI + GFD por estación

Tabla 1: Cruce de señal SAR, NDVI y frecuencia de inundación histórica por estación, restringido al AOI acotado SFF + VPI Salamanca.

Estación	Naturaleza	Dentro AOI acotado	SAR diff (dB)	NDVI sept-2020	Eventos GFD	Interpretación
Isla Boquerón	Limnológica	No	N/A	-0,018	10 de 16	Fuera del AOI: sobre lámina de agua del complejo lagunar central
Punta Cerro	Limnológica	No	N/A	-0,078	10 de 16	Fuera del AOI: sobre lámina de agua del complejo lagunar central
Punta Chino	Limnológica	No	N/A	0,200	9 de 16	Fuera del AOI: sobre lámina de agua del complejo lagunar central

Río Sevilla	Limnológica	No	N/A	0,050	10 de 16	Fuera del AOI: sobre lámina de agua del complejo lagunar central
Caño Palos	Manglar	Sí	+0,15	0,400	2 de 16	Sin afectación SAR mayor
CP Aguas Negras (legacy: CP Pajarales)	Manglar	No	N/A	0,300	9 de 16	Fuera del AOI: oeste del SFF, en zona riberrana
Caño Clarín	Manglar	No	N/A	0,500	1 de 16	Fuera del AOI: sur del SFF, sobre zona de rehabilitación hidráulica
CP Luna (legacy: VIPIS)	Manglar	Sí	+0,12	0,350	9 de 16	Sin afectación SAR mayor

F.2 Transiciones JRC Global Surface Water 1984–2021

Tabla 2: Transiciones JRC Global Surface Water (1984–2021) dentro del AOI acotado SFF + VPI Salamanca. El AOI contiene 385,3 km² de agua permanente (>75 % del tiempo) y 44,1 km² estacional (25–75 %), de modo que casi la mitad del polígono protegido es lámina de agua.

Transición JRC dentro del AOI acotado	Área (km ²)	Interpretación
Permanente	377,75	Lámina de agua estable
Nuevo permanente	23,55	Cuerpos nuevos consolidados
Permanente perdido	18,55	Cuerpos de agua secados
Estacional	17,98	Zonas con régimen estacional estable
Nuevo estacional	31,31	Nuevas áreas de inundación estacional
Estacional perdido	29,38	Zonas que dejaron de inundarse
Permanente a estacional	18,54	Retroceso parcial de lámina permanente
Efímero estacional	49,30	Inundación intermitente sin patrón estacional
Efímero permanente	1,74	Agua intermitente persistente

F.3 Entorno de ejecución (runtime Docker)

Tabla 3: Entorno de ejecución completo del proyecto.

Componente	Especificación
Contenedor	Docker sig_unal v1.11 (Ubuntu + RStudio Server)
Python	3.12.3 + geopandas, samgeo, leafmap, rasterio, geopandas
R	4.3.3 + terra, sf, tidyverse, bfast, tmap
Julia	1.11.3 + DataFrames, CSV, GeoJSON, Statistics
Quarto	1.4.550 (informe reproducible)
Control de versiones	Git + GitHub
Análisis geoespacial en la nube	Google Earth Engine (API Python)

F.4 Quiebres BFAST sobre las ocho estaciones del proyecto

Tabla 4: Quiebres estructurales detectados por BFAST sobre las ocho estaciones del proyecto en la serie combinada Landsat 8 + Sentinel-2 (2013–2025). El análisis refinado sobre las cuatro estaciones de manglar denso se reporta en la Tabla 5 del cuerpo del informe principal.

Estación	Quiebres (h=0,15)	Fecha principal	Quiebres (h=0,10)	Evento asociado
CP Aguas Negras (legacy: CP Pajarales)	1	2016-10	1	El Niño 2015–2016
Caño Clarín	1	2016-09	1	El Niño 2015–2016
Caño Palos	1	2015-06	No estimado	El Niño (inicio)
Isla Boquerón	2	2016-04, 2018-05	2	El Niño + transición
Punta Cerro	1	2016-11	3	El Niño + La Niña + recuperación
Punta Chino	1	2016-05	2	El Niño 2015–2016
Río Sevilla	1	2016-12	1	El Niño 2015–2016
CP Luna (legacy: VIPIS)	2	2016-04, 2022-03	2	El Niño + recuperación

F.5 Parches de manglar truncados por la frontera del AOI

Tabla 5: Parches de manglar truncados por la frontera del AOI acotado (predicado DE-9IM *intersects* con tolerancia de 30 m). Los parches se cuentan agregados como features completos en *geopandas*.

Periodo	Parches	Parches en borde	% en borde	Área en borde (ha)
Degradación (2020-S2)	17	6	35,3	5.104,3
Recuperación (2022-S1)	17	8	47,1	8.325,7
Actual (2024–2025)	15	8	53,3	5.237,9

F.6 Principales anomalías NDVI ($z < -2$)

Tabla 6: Anomalías significativas de NDVI ($z < -2$) en la serie combinada 2013–2025, ordenadas por z-score decreciente.

Estación	Fecha	NDVI	z-score	Sensor
Isla Boquerón	2020-09	-0,018	-3,36	Sentinel-2
Caño Clarín	2018-03	0,166	-3,15	Sentinel-2
CP Luna (legacy: VIPIS)	2016-04	-0,291	-2,93	Landsat 8
Caño Clarín	2025-03	0,223	-2,77	Sentinel-2
Caño Palos	2024-09	0,272	-2,66	Sentinel-2
CP Aguas Negras (legacy: CP Pajarales)	2018-03	0,203	-2,50	Sentinel-2
Punta Cerro	2020-09	-0,078	-2,46	Sentinel-2
CP Aguas Negras (legacy: CP Pajarales)	2022-09	0,217	-2,40	Sentinel-2

F.7 Flujo de datos del pipeline multilinguaje

Tabla 7: Flujo de datos del pipeline multilinguaje.

Paso	Herramienta	Lenguaje	Entrada	Salida
1. Adquisición	GEE + geemap	Python	Sentinel-2 / Landsat	Pilas de índices (.tif)
2. Series de tiempo	pandas + BFAST	Python / R	Índices + estaciones	Z-scores, periodos (.csv)
3. Segmentación	SamGeo + umbrales	Python	Composiciones RGB	Parches manglar (.geojson)
4. Métricas	DataFrames.jl	Julia	Parches vectoriales	Tabla de métricas (.csv)
4b. Topología DE-9IM	geopandas + shapely	Python	Parches en EPSG:9377	Tabla parches_topología (.csv)
5. Inundación SAR	GEE Sentinel-1	Python	SAR VH seco vs húmedo	Mapa inundación (.tif)
6. Dashboard	geemap	Python	Todas las capas	Dashboard (.html)
7. Forzamiento ERA5	cdsapi + xarray	Python	NetCDF ERA5-Land	Anomalías y correlación (.csv)
8. Cubo stars	stars + sf	R	TIFs trimestrales S2	Series por estación (.csv)
9. Validación multilingüe	pandas	Python	Series Python + R	RMSE/rho (.csv)
10. RF benchmark	GEE smileRandomForest	Python	Sentinel-2 + INVEMAR / WorldCover	F1, Recall, Precisión (.csv), importancia de variables (.png)
11. SAR continuo VH	GEE Sentinel-1 + pandas	Python	Sentinel-1 GRD 2018-2025	Serie SAR-VH mensual, correlación con NDVI (.csv)
12. Alertas tempranas	pandas + matplotlib	Python	Series NDVI + SAR + bfast	Semáforo estaciones (.csv) y mapa (.png)

F.8 Eventos GFD con mayor área inundada sobre el AOI acotado

Tabla 8: Eventos de inundación con mayor área afectada dentro del AOI acotado (Global Flood Database, 2001-2017).

Evento	Inicio	Fin	Área (km ²)	Días
DFO_2625	2005-02-11	2005-02-26	299,2	15
DFO_2588	2004-11-20	2004-11-27	274,8	7
DFO_2761	2005-09-15	2005-12-16	239,4	92
DFO_1996	2002-07-20	2002-07-31	233,9	11
DFO_4495	2017-08-04	2017-08-21	221,3	17
DFO_3212	2007-10-01	2007-12-10	211,5	70
DFO_3750	2010-11-15	2010-12-20	190,1	35
DFO_3754	2010-11-25	2010-12-20	175,0	25
DFO_3421	2008-12-13	2008-12-14	151,9	1
DFO_3311	2008-05-27	2008-05-28	78,8	1

F.9 Correlación SAR-VH × NDVI por estación (rezagos 0-3 meses)

Tabla 9: Correlación de Pearson entre la serie mensual Sentinel-1 SAR-VH y el NDVI z-score derivado de Sentinel-2 para rezagos de 0 a 3 meses, calculada sobre las ocho estaciones entre 2018 y 2025. Valores en negrita: correlaciones significativas ($p < 0,001$) sobre las cuatro estaciones de manglar denso del Complejo de Pajarales.

Estación	Naturaleza	ρ lag 0	ρ lag 1	ρ lag 2	ρ lag 3	n
CP Aguas Negras	manglar	+0,807	+0,788	+0,773	+0,758	85
CP Luna	manglar	+0,731	+0,710	+0,717	+0,722	83
Caño Clarín	manglar	+0,640	+0,380	-0,025	-0,127	63
Caño Palos	manglar	+0,462	+0,406	+0,379	+0,434	64
Isla Boquerón	limnológica	+0,166	+0,192	+0,205	+0,226	70
Punta Cerro	limnológica	+0,008	+0,086	+0,043	+0,053	70
Punta Chino	limnológica	+0,134	+0,168	+0,178	+0,203	70
Río Sevilla	Limnológica	-0,159	-0,102	-0,077	-0,058	71

F.10 Datacubes NetCDF materializados

Tabla 10: Datacubes NetCDF CF-1.8 materializados sobre el AOI acotado en EPSG:9377 (MAGNA-SIRGAS Origen Nacional), comprimidos con zlib nivel 4.

Archivo	Sensor	Frecuencia	Periodo	Bandas	Tamaño
cgs_datacube_periodos.nc	Sentinel-2	Tres composiciones discretas	Degradación (2020 H2), recuperación (2022 H1), actual (2024–2025)	RGB (B4, B3, B2)	40 MB
cgs_datacube_trimestral.nc	Sentinel-2	Trimestral	2018-Q1 a 2025-Q4 (31 trimestres)	NDVI, NDWI, CMRI	275 MB
cgs_datacube_landsat.nc	Landsat 8/9	Anual	2013–2025 (13 años)	NDVI, NDWI, CMRI	119 MB

F.11 Correlación ENSO-NDVI por naturaleza espectral

Tabla 11: Correlación de Pearson entre índices ENSO globales (ONI y SOI de NOAA) y NDVI z-score desagregada por naturaleza espectral.

Naturaleza	Rezago (meses)	ρ ONI	ρ SOI	n
Manglar	0	+0,027	+0,143	86
Manglar	1	-0,007	+0,198	85
Manglar	2	-0,039	+0,146	84
Manglar	3	-0,070	+0,058	83
Limnológica	0	-0,121	+0,201	72
Limnológica	1	-0,089	+0,120	71
Limnológica	2	-0,054	+0,135	70
Limnológica	3	-0,014	+0,153	69

F.12 Correlación caudal IDEAM-NDVI por estación hidrológica

Tabla 12: Correlación de Pearson entre anomalía de caudal IDEAM y NDVI z-score, desagregada por estación hidrológica, naturaleza espectral y rezago temporal.

Estación	Naturaleza	Rezago (meses)	ρ caudal	n
El Banco (Magdalena)	Manglar	0	+0,064	74

El Banco (Magdalena)	Manglar	1	+0,039	73
El Banco (Magdalena)	Manglar	2	+0,108	72
El Banco (Magdalena)	Manglar	3	+0,256	71
El Banco (Magdalena)	Limnológica	0	+0,181	61
El Banco (Magdalena)	Limnológica	1	+0,233	60
El Banco (Magdalena)	Limnológica	2	+0,043	59
El Banco (Magdalena)	Limnológica	3	+0,050	58
Ganadería Caribe (Aracataca)	Manglar	0	+0,196	68
Ganadería Caribe (Aracataca)	Manglar	1	+0,224	67
Ganadería Caribe (Aracataca)	Manglar	2	+0,184	66
Ganadería Caribe (Aracataca)	Manglar	3	+0,180	65
Ganadería Caribe (Aracataca)	Limnológica	0	+0,107	58
Ganadería Caribe (Aracataca)	Limnológica	1	+0,263	57
Ganadería Caribe (Aracataca)	Limnológica	2	+0,267	56
Ganadería Caribe (Aracataca)	Limnológica	3	+0,150	55

F.13 Correlación CHIRPS-NDVI sobre cuencas aportantes

Tabla 13: Correlación de Pearson entre anomalía mensual CHIRPS sobre cuencas aportantes y NDVI z-score de las estaciones de la CGSM.

Cuenca CHIRPS	Naturaleza	Rezago (meses)	pprecip	n
Magdalena alta-media	Manglar	0	+0,075	86
Magdalena alta-media	Manglar	1	+0,170	85
Magdalena alta-media	Manglar	2	+0,097	84
Magdalena alta-media	Manglar	3	+0,252	83
Magdalena alta-media	Limnológica	0	+0,276	72
Magdalena alta-media	Limnológica	2	+0,268	70
Sierra Nevada oeste	Manglar	3	+0,281	83
Sierra Nevada oeste	Limnológica	2	+0,359	70

F.14 Correlación ERA5-Land vs NDVI por naturaleza espectral

Tabla 14: Correlación entre anomalías climáticas ERA5-Land (precipitación y temperatura a 2 m) y NDVI z-score, desagregada por naturaleza espectral.

Naturaleza	Rezago (meses)	ρ precip vs NDVI z	ρ T2m vs NDVI z	n
Manglar	0	-0,081	+0,022	86
Manglar	1	-0,081	+0,040	85
Manglar	2	-0,123	-0,018	84
Manglar	3	-0,020	-0,087	83
Limnológica	0	+0,082	-0,173	72
Limnológica	1	+0,108	-0,149	71
Limnológica	2	+0,292	-0,144	70
Limnológica	3	+0,271	-0,201	69

