

Pipeline multilenguaje (Python, R, Julia) para el monitoreo de manglar en la CGSM (2013–2025)

Lina María Quintero Fonseca

2026-05-25

Universidad Nacional de Colombia
Facultad de Ciencias Agrarias · Maestría en Geomática
Programación en SIG · Proyecto Final

Repositorio: <https://github.com/linaq11/proyecto-cgsm-curso>

1 Resumen

La Ciénaga Grande de Santa Marta (CGSM), sitio Ramsar N° 562 y Reserva de la Biosfera UNESCO, sostiene el complejo lagunar costero más extenso de Colombia. Su cobertura de manglar ha experimentado ciclos recurrentes de degradación y recuperación asociados a la hipersalinización crónica, los eventos El Niño-Oscilación del Sur (ENSO) y la regulación hídrica derivada de la apertura de canales entre 1996 y 1998. El presente estudio caracteriza la dinámica espaciotemporal del manglar de la CGSM entre 2013 y 2025 sobre las 835,3 km² del área protegida oficial (Santuario de Fauna y Flora y Vía Parque Isla de Salamanca) mediante un pipeline multilenguaje (Python, R y Julia) que integra 929 observaciones mensuales del Índice de Vegetación de Diferencia Normalizada (NDVI) combinadas Landsat 8 + Sentinel-2, segmentación guiada por prompts con SamGeo, métricas de fragmentación en EPSG:9377, detección de inundación con radar Sentinel-1 SAR y cuatro forzamientos climático-hidrológicos (ERA5-Land, índices ENSO de la NOAA, caudal IDEAM y precipitación CHIRPS). Los resultados identifican quiebres bfast generalizados en 2016 y un evento de mortandad puntual en septiembre 2020 con 43,08 km² de inundación bajo dosel; la cobertura se contrae de 12.426 a 4.037 ha con consolidación estructural (área media de parche 157 → 269 ha) y el NDVI mediano del dosel se recupera de 0,60 a 0,80 desde 2022. La validación doble contra INVEMAR 1:25.000 y ESA WorldCover v200 arroja $F1 = 0,583$ y $0,548$ para el clasificador por umbrales, y $F1 = 0,826$ y $0,889$ para Random Forest. El pipeline materializa el Nivel 2 del paradigma Digital Twin mediante un módulo operativo de alertas tempranas que reporta cinco estaciones estables, tres en alerta y ninguna crítica al cierre de 2025.

Palabras clave: Ciénaga Grande de Santa Marta, manglar, NDVI, bfast, Sentinel-2, Landsat 8, Sentinel-1 SAR, SamGeo, Random Forest, ENSO, La Niña, Google Earth Engine, pipeline multilenguaje.

2 Introducción y Justificación

La Ciénaga Grande de Santa Marta, CGSM, constituye el sistema lagunar costero más extenso de Colombia y uno de los humedales de mayor relevancia ecológica en América Latina, gracias a que

sus extensas coberturas de manglar cumplen funciones de regulación hídrica, protección costera y sostenimiento de la pesca artesanal regional (Instituto de Investigaciones Marinas y Costeras [INVEMAR], 2024). Reconocida como sitio Ramsar desde 1998 y Reserva de Biosfera UNESCO desde 2000, la CGSM ha sido objeto de múltiples figuras de protección que reconocen su importancia ecológica; sin embargo, desde la década de los noventa el sistema ha experimentado una degradación severa y cíclica de su cobertura de manglar, impulsada por la interrupción del flujo hídrico tras la construcción de la carretera Ciénaga–Barranquilla en los años cincuenta, la hipersalinización resultante, la deforestación para actividades agropecuarias y la intensificación de los eventos ENSO, especialmente La Niña, de modo que aunque la reapertura de cinco canales hidráulicos entre 1996 y 1998 promovió una recuperación parcial, la dinámica del ecosistema continúa siendo inestable y los ciclos de degradación y recuperación no están completamente caracterizados a alta resolución espaciotemporal (INVEMAR, 2024).

El monitoreo de manglares mediante teledetección ha evolucionado de manera sostenida en la última década, de modo que se ha transitado del inventario global a partir de mosaicos Landsat circa-2000 (Giri et al., 2011) y de las series globales continuas en alta resolución temporal (Hamilton y Casey, 2016) hacia el uso de la colección Sentinel-2, cuya resolución espacial de 10 metros y temporal de 5 días ha mejorado sustancialmente la capacidad de detectar cambios fenológicos y perturbaciones a escala local. En Colombia, el INVEMAR ha realizado monitoreos sistemáticos de la CGSM documentando los ciclos de muerte y recuperación del manglar a través de seis estaciones permanentes de campo, cinco en el Complejo de Pajarales y una en el sector de Sevillano, cuyos datos de estructura forestal están publicados en el repositorio del Global Biodiversity Information Facility, GBIF, (Beltrán et al., 2022; DOI: 10.15472/0fqdp4). No obstante, estos estudios se basan principalmente en interpretación visual o clasificaciones supervisadas clásicas, sin recurrir al análisis automático basado en modelos fundacionales como el Segment Anything Model, SAM, de Meta AI, adaptado para datos geospaciales a través de SamGeo (Wu y Osco, 2023), que permite realizar segmentación guiada por prompts ,el modelo separa cada objeto visible en la imagen guiado por puntos o cajas que el usuario marca, sin necesidad de grandes conjuntos de datos etiquetados.

En este marco, la integración de herramientas de Inteligencia Artificial Geoespacial, GeoAI, con plataformas de geocomputación en la nube como Google Earth Engine, GEE, abre una vía metodológica para el monitoreo costero a alta resolución espaciotemporal. El presente proyecto se propone desarrollar un pipeline multilenguaje, Python, R y Julia, que articule el análisis de series de tiempo de índices espectrales con la segmentación automática de cobertura de manglar, de manera que el resultado pueda servir como componente de observación de un futuro Digital Twin costero para la CGSM, sin pretender constituirse en sí mismo como tal en su versión actual. La caracterización espaciotemporal del manglar en la CGSM constituye un insumo para la gestión de riesgos de inundación y la formulación de política pública ambiental; en febrero de 2026 se firmó el Plan de Manejo Ambiental del sitio Ramsar Sistema Delta Estuarino del Río Magdalena–CGSM, con una vigencia de diez años, y que orienta el seguimiento ambiental permanente del humedal (Comisión Conjunta CGSM, 2026), de modo que un pipeline automatizado como el que aquí se propone resulta pertinente para alimentar dicho seguimiento con productos cartográficos reproducibles.

A partir de lo anterior, el presente estudio se articula en torno a la siguiente pregunta de investigación: **¿cómo ha variado la cobertura, la fragmentación y el vigor del manglar de la Ciénaga Grande de Santa Marta entre 2013 y 2025, y qué evidencia cuantitativa permite atribuir las perturbaciones detectadas a forzamientos climáticos asociados al evento La Niña 2020–2021?**

3 Estado del Arte

El monitoreo satelital de manglares ha avanzado en las últimas tres décadas: Giri et al. (2011) produjeron el primer inventario global moderno sobre un mosaico Landsat circa-2000 a 30 m, mientras que Hamilton y Casey (2016) extendieron la observación a una serie temporal anual continua mediante el conjunto CGMFC-21 para el periodo 2000–2012. Con el lanzamiento de Sentinel-2, la resolución espacial de 10 m y la revisita de 5 días permitieron construir series temporales densas que capturan la variabilidad estacional e interanual de la cobertura vegetal costera, en este sentido Raza et al. (2024) demostraron que el análisis de NDVI Sentinel-2 en GEE detecta tendencias de deterioro del manglar aun cuando la extensión del bosque se mantiene estable, razón por la cual las estimaciones de cobertura deben acompañarse de indicadores de condición. En cuanto a índices espectrales, Gupta et al. (2018) propusieron el Combined Mangrove Recognition Index ($CMRI = NDVI - NDWI$, donde NDWI es el Índice de Diferencia Normalizada de Agua), que alcanza exactitud de clasificación de 73,43 % frente al 56,29 % del NDVI estándar para discriminar manglar de otras coberturas en ambientes estuarinos. A escala global, el Global Mangrove Watch v3.0 de JAXA (Bunting et al., 2022) provee la referencia más completa para 1996–2020 mediante detección de cambios sobre series SAR L-band, mientras que a escala nacional el INVEMAR generó en 2020 la cartografía oficial colombiana 1:25.000 con clasificación supervisada en GEE sobre imágenes ópticas y radar (INVEMAR, 2020). La narrativa dominante en la literatura global, construida sobre archivos Landsat, atribuye la pérdida de manglar a la presión antrópica directa: Goldberg et al. (2020) reportan el 62 % de la pérdida mundial 2000–2016 ligada al cambio de uso del suelo, con casi el 80 % concentrado en seis países del sudeste asiático. Sin embargo, este marco invisibiliza las pérdidas graduales que dominan en otras geografías, tal como demuestran Murillo-Sandoval et al. (2022) al reconstruir 36 años de cobertura colombiana con LandTrendr y documentar 48.000 ha de disminución dominadas por degradación de manglar denso a otra vegetación (38.469 ± 2.829 ha) antes que por conversión abrupta. La tensión global frente a nacional sustenta la necesidad de aproximaciones por trayectorias temporales densas, capaces de capturar transiciones intermedias entre cobertura plena y suelo desnudo.

La adopción de Google Earth Engine para el monitoreo de manglares se ha acelerado en los últimos años porque permite procesar miles de imágenes sin infraestructura computacional local. Selvaraj y Gallego-Pérez (2023) aplicaron GEE al mapeo del Pacífico colombiano combinando Landsat óptico y SAR ALOS-2/PALSAR-2 con un clasificador Random Forest, en tanto que Yancho et al. (2020) presentaron la Google Earth Engine Mangrove Mapping Methodology, GEEMMM, como herramienta abierta concebida para que gestores costeros sin formación especializada puedan cartografiar manglares en la nube, validada sobre la totalidad del litoral de Myanmar. La presente investigación adopta una arquitectura análoga, procesamiento íntegro en GEE, máscaras de nube, composiciones temporales, aunque sustituye la clasificación supervisada por umbrales NDVI y CMRI calibrados localmente y se valida adicionalmente con un benchmark Random Forest. Dado que toda cartografía de cambio exige cuantificar su incertidumbre, las recomendaciones canónicas de Olofsson et al. (2014) sobre diseño de muestreo probabilístico, matriz de error en proporciones de área e intervalos de confianza para superficies de cambio constituyen la referencia metodológica que se desarrolla en la sección de Validación. En la CGSM específicamente, el INVEMAR realiza monitoreo continuo desde la reapertura de los canales hidráulicos entre 1996 y 1998 sobre seis estaciones permanentes (INVEMAR, 2024), con datos de estructura forestal 2013–2019 publicados en GBIF (Beltrán et al., 2022); el antecedente local más cercano corresponde a Vinasco et al. (2020), quienes cuantificaron cambios de cobertura 2013–2018 sobre 119 escenas Landsat-8 con Random Forest sobre seis clases CORINE Land Cover, reportando contracción de áreas húmedas del 27 % al 12 %, aunque sin aislar la cobertura de manglar como clase específica, vacío que el presente trabajo

aborda al combinar Landsat 8/9 con Sentinel-2 íntegramente en GEE.

La aparición de modelos fundacionales como el Segment Anything Model de Meta AI (Kirillov et al., 2023), adaptado a datos geospaciales a través de SamGeo (Wu y Osco, 2023), permite realizar segmentación guiada por prompts sin grandes conjuntos de datos etiquetados, mediante prompts geométricos o prompts textuales aportados por el detector Grounding DINO acoplado. La plataforma OpenGeoAI, liderada por el profesor Qiusheng Wu, integra geemap, leafmap y SamGeo con GEE para construir cadenas de procesamiento geoespacial completas en la nube. El concepto de Digital Twin aplicado a humedales, explorado recientemente como marco para el monitoreo y la gestión de ecosistemas (Lu et al., 2026), combina observación de la Tierra, modelos físicos y aprendizaje automático para reflejar dinámicamente el estado del sistema. En este marco, el componente de monitoreo basado en teledetección desarrollado en este proyecto podría servir como capa de actualización para un futuro gemelo digital, sin pretender agotar la complejidad de un sistema acoplado de observación-modelación-simulación.

4 Objetivos

4.1 Objetivo general

Desarrollar un pipeline GeoAI multilenguaje para el monitoreo de la dinámica espaciotemporal de la cobertura de manglar en la Ciénaga Grande de Santa Marta (2013–2025).

4.2 Objetivos específicos

1. Construir un datacube multitemporal de índices espectrales (NDVI, NDWI, CMRI) para la CGSM en el periodo 2013–2025.
2. Identificar los periodos de degradación y recuperación del manglar entre 2013 y 2025 mediante análisis de anomalías z-score y quiebres bfast.
3. Validar la segmentación automática de cobertura de manglar contra cartografía de referencia (INVEMAR 1:25.000 y ESA WorldCover v200).

5 Área de estudio




Figura 1: Localización del área de estudio. (a) Colombia con el Magdalena resaltado; (b) departamento del Magdalena con las ciudades de referencia y el AOI acotado en rojo; (c) composite Sentinel-2 RGB del periodo 2024-2025 sobre el AOI acotado (SFF CGSM + VPI, 835 km²), con las cinco estaciones INVEMAR-GBIF (triángulos rojos) y la cobertura de manglar segmentada por SamGeo (verde traslúcido).

El área de estudio comprende la CGSM y su zona de influencia costera, ubicada en el departamento del Magdalena, Colombia, entre aproximadamente 10°20' N–11°05' N y 74°10' W–74°55' W. El proyecto opera con dos delimitaciones de Área de Interés (AOI) anidadas que cumplen funciones distintas. La primera, denominada **AOI envolvente** y delimitada con 34 vértices sobre 5.073 km², se utilizó únicamente en la iteración preliminar del proyecto (marzo de 2026) y operó como línea base de referencia antes del acotamiento metodológico; comprende la Vía Parque Isla de Salamanca, el Complejo de Pajarales, el Santuario de Fauna y Flora CGSM, los canales hidráulicos rehabilitados, Caño Clarín, Aguas Negras y Renegado, y las desembocaduras de los ríos Sevilla, Aracataca y Fundación. La segunda, denominada **AOI acotado** y delimitada con 835,3 km² sobre la unión de los polígonos oficiales del Santuario de Fauna y Flora CGSM (26.810 ha) y la Vía Parque Isla de Salamanca extraídos del Registro Único Nacional de Áreas Protegidas (RUNAP), constituye el área sobre la cual se sostienen todos los resultados reportados en el cuerpo del informe v6; este acotamiento obedece a que la inclusión de vegetación riberrana, salitral y zonas agropecuarias en el AOI envolvente inflaba sistemáticamente las cifras de manglar potencial y comprometía la comparabilidad con la cartografía oficial de manglares de Colombia (INVEMAR, 2020) y con el Global Mangrove Watch (Bunting et al., 2022), referencias que también se acotan al humedal propiamente dicho.

Para el análisis de series de tiempo se definieron 8 estaciones de muestreo, de las cuales 5 corresponden a estaciones con coordenadas exactas obtenidas del conjunto de datos de monitoreo de estructura de manglares del INVEMAR publicado en GBIF (Beltrán et al., 2022; DOI: 10.15472/0fqdp4), Isla Boquerón (10,962 N, 74,298 W), Punta Cerro (10,973 N, 74,283 W), Punta Chino (10,912 N, 74,305 W), Río Sevilla (10,880 N, 74,325 W) y Caño Palos (10,758 N, 74,471 W), mientras que las 3 restantes son estaciones complementarias seleccionadas sobre cobertura de manglar verificada mediante NDVI > 0,4 en composites Sentinel-2 de 2024, con el propósito de representar el Complejo de Pajarales y la zona de rehabilitación hidrológica del Caño Clarín.

6 Fuentes de Datos

Los datos provienen tanto de plataformas de geocomputación en la nube como de repositorios institucionales abiertos. Siguiendo la declaración cuádruple de resolución recomendada por Gomasca (2010), las dos colecciones ópticas centrales operan con resoluciones espaciales nativas de 10 a 60 m en el instrumento Sentinel-2 MSI L2A (MultiSpectral Instrument, Level 2A de reflectancia superficial) y de 15 a 30 m en Landsat 8/9 OLI (Operational Land Imager), revisita combinada de 5 y 8 días respectivamente, profundidad radiométrica de 12 bits y cobertura espectral en visible, infrarrojo cercano (NIR) e infrarrojo de onda corta (SWIR). El detalle completo de bandas, ventanas espectrales y proveedores institucionales se reporta en la tabla ??.

Tabla 1: Fuentes de datos utilizadas en el pipeline para el monitoreo de manglar.

Dataset / Fuente	Tipo	Uso en el proyecto	Acceso
Sentinel-2 MSI L2A (ESA)	789 imágenes (2018-2025)	Índices espectrales y RGB para SamGeo	GEE · S2_SR_HARMONIZED
Landsat 8 OLI (USGS)	345 registros (2013-2017)	Serie histórica NDVI complementaria	GEE · LC08/C02/T1_L2
Sentinel-1 SAR (ESA)	85 imágenes (2020)	Detección de inundación bajo dosel	GEE · S1_GRD
Global Flood Database	16 eventos (2001-2017)	Registro histórico de inundaciones	GEE · GLOBAL_FLOOD_DB
JRC Global Surface Water	Raster global	Transiciones y estacionalidad hídrica	GEE · JRC/GSW1_4
SRTM v3 (NASA)	DEM 30 m	Restricción de elevación (< 10 m)	GEE · SRTMGL1_003
Monitoreo manglar INVEMAR	376 registros (2013-2019)	Coordenadas estaciones de muestreo	GBIF · 10.15472/0fqdp4
Global Mangrove Watch v4.0	Raster (2020)	Validación de clasificación	GEE · sat-io/GMW

El conjunto de datos satelitales del proyecto se apoya principalmente en las misiones Landsat 8 y Landsat 9 de la NASA y el Servicio Geológico de Estados Unidos (USGS, U.S. Geological Survey), el modelo digital de elevación SRTM v3 (Shuttle Radar Topography Mission de la NASA) y los índices climáticos ENSO del Climate Prediction Center (CPC) de la NOAA, complementados con la Global Flood Database (GFD) del Dartmouth Flood Observatory, derivada de MODIS (Moderate Resolution Imaging Spectroradiometer) NASA y Sentinel-1 ESA, para el inventario histórico de inundaciones. La capa óptica de alta resolución espacial y temporal proviene de la constelación europea Sentinel-2 de la Agencia Espacial Europea (ESA, European Space Agency, programa Copernicus), y la observación radar de Sentinel-1 (ESA-Copernicus). La segmentación guiada por prompts del manglar se ejecuta con la biblioteca SamGeo (Wu y Osco, 2023), adaptación geoespacial del *Segment Anything Model* de Meta AI. Los registros hidrométricos del río Magdalena en la estación El Banco y del río Aracataca en Ganadería Caribe provienen del IDEAM, mientras que la cartografía de referencia para la validación es la cobertura oficial colombiana de manglares 1:25.000 publicada por INVEMAR (2020) y la cartografía global ESA WorldCover v200 (Zanaga et al., 2022).

7 Metodología y código

El proyecto se desarrolla siguiendo un pipeline modular y reproducible organizado en cuatro fases y un módulo de validación que se ejecutan dentro de un contenedor Docker, sig_unal v1.11, que integra

Python 3.12, R 4.3.3, Julia 1.11.3 y Quarto 1.4, de modo que se garantiza la replicabilidad completa del entorno de análisis. Cada fase se implementa aprovechando las fortalezas del lenguaje más adecuado para la tarea, y la interoperabilidad entre fases se mantiene mediante formatos estándar, GeoTIFF, GeoJSON y CSV.

7.1 Distribución multilingüe de responsabilidades

La arquitectura distribuye las tareas entre los tres lenguajes del curso según la conveniencia disciplinar de cada fase y no como mera coexistencia obligatoria. **Python** sustenta la adquisición en Google Earth Engine, la segmentación con SamGeo, los datacubes con **xarray**, el clasificador Random Forest y el dashboard. **R** se reserva para los quiebres bfast sobre las series NDVI, el cubo **stars** y las réplicas estadísticas de ENSO y caudal IDEAM con **tidyverse**. **Julia** ejecuta el cómputo geométrico sobre miles de polígonos: fragmentación (NP, MSI, NND), área en EPSG:9377 con **shoelace** y predicados DE-9IM con **LibGEOS.jl**. La equivalencia operativa entre los tres lenguajes se demuestra mediante cuatro validaciones cruzadas documentadas en la sección homónima de Resultados.

Tabla 2: Distribución de responsabilidades técnicas entre los tres lenguajes del proyecto, con las librerías centrales y los notebooks que materializan cada función. La elección obedece a las fortalezas disciplinares de cada ecosistema y se valida cruzadamente en la sección de Validación cruzada multilingüe.

Lenguaje	Función técnica	Librerías clave	Notebooks / scripts principales
Python	Adquisición GEE, segmentación SAM, Random Forest, datacubes, dashboard	geemap , samgeo , xarray , rioxarray , rasterio , geopandas , folium , cdsapi	01_gee_acquisition, 02_time_series, 03_segmentation_acotado, 05_flooding_nasa_acotado, 07_era5_clima, 11_random_forest_benchmark, 12_sentinel1_sar_serie
R	Detección de quiebres bfast, cubo stars, réplicas estadísticas	bfast , stars , sf , terra , tidyverse	src/R/03_bfast_ndvi.R, src/R/05_stars_cubo.R, notebooks/02b_bfast_ndvi.R, 11b_indicesenso_noaa_R, 12c_caudal_ideam_R
Julia	Métricas de fragmentación, topología DE-9IM (Dimensionally Extended 9-Intersection Model, modelo formal que clasifica relaciones espaciales entre geometrías como intersección, contención o disjunción), cómputo geométrico	GeoJSON.jl , DataFrames.jl , LibGEOS.jl , Statistics	src/julia/04_fragmentacion.jl, notebooks/04c_topología_julia, 14_validacion_trilingual

7.2 Fase 1: Construcción del datacube multitemporal (Python + geemap)

La primera fase construye un datacube ,estructura tridimensional X-Y-tiempo que apila las observaciones satelitales de una misma área en una sola pila ordenada, que organiza las observaciones de la CGSM a resoluciones nativas de 10 a 30 m según el sensor. Se ensamblan 789 imágenes Sentinel-2 SR Harmonized para 2018–2025 filtradas por cobertura de nubes inferior al 20 %, sobre las cuales se calculan NDVI, NDWI y el índice CMRI propuesto por Gupta et al. (2018) para discriminar manglar en ambientes estuarinos. El datacube se materializa como tres archivos

NetCDF con convenciones CF-1.8 re proyectados a EPSG:9377 y resampleados a 30 m, lo que permite que Python, R y Julia los lean con el mismo bloque de código sin re-consultar la API de GEE. La construcción de la colección Sentinel-2 con cálculo de índices y la lectura perezosa del NetCDF se documentan en el Anexo E, ítems E.1.a y E.1.d.

El detalle de los tres datacubes NetCDF materializados (archivo, sensor, frecuencia, periodo, bandas y tamaño) se reporta en el Anexo F.10 del documento complementario, y el bloque de lectura perezosa con `xarray` se documenta en el Anexo E, ítem E.1.a.

La diferencia espacial entre la mediana de NDVI del estado actual (julio 2024–junio 2025) y la del periodo de degradación (julio–diciembre 2020), calculada directamente sobre el datacube trimestral CF-1.8, permite leer en un solo mapa las zonas que recuperaron vigor frente a aquellas que perdieron cobertura, de modo que la figura figura ?? sostiene cualitativamente lo que las métricas de fragmentación describen cuantitativamente. Las áreas en azul corresponden a píxeles que ganaron al menos 0,1 unidades NDVI entre ambos periodos, consistentes con la regeneración del manglar, mientras que las áreas en rojo, concentradas principalmente en el borde norte del Vía Parque y en sectores hipersalinos del Santuario, marcan reducciones que pueden asociarse tanto a estresores climáticos persistentes como a heterogeneidad fenológica del manglar entre ambas ventanas temporales.




Figura 2: Cambio en la mediana de NDVI entre el estado actual (2024–2025) y el periodo de degradación (2020 H2) sobre el AOI acotado. Azul indica ganancia de vigor (regeneración); rojo indica pérdida. Coordenadas en metros (EPSG:9377, MAGNA-SIRGAS).

7.3 Fase 2: Análisis de series de tiempo (Python + pandas / R + bfast, Breaks For Additive Season and Trend)

Se extraen series temporales mensuales de NDVI sobre las ocho estaciones de muestreo mediante `reduceRegion` en GEE con buffer de 500 m, combinando Landsat 8 Collection 2 (345 registros, 2013–2017) y Sentinel-2 SR Harmonized (584 registros, 2018–2025) para una serie de 929 observaciones que cubre 12 años. Sobre cada estación se calcula el z-score temporal, que identifica como anomalías significativas los meses con $z < -2$, y se aplica el algoritmo `bfast` en R para detectar quiebres

estructurales en la tendencia de largo plazo. La corrección del factor de escala USGS, los parámetros de `bfast` (h) y la implementación del z-score en Python se documentan en el Anexo E, ítems E.1.b y E.1.e.

7.4 Fase 3: Segmentación automática con SamGeo (Python + samgeo)

Se aplica SamGeo con backbone `vit_b` sobre los composites RGB de los tres periodos de referencia (degradación 2020 H2, recuperación 2022 H1, actual 2024–2025), remuestreados de 10 a 30 m por limitaciones de memoria. Las máscaras se vectorizan y se clasifican por estado (manglar / no manglar) según el CMRI medio de cada parche, filtrando por área entre 1 y 5.000 ha. El detalle de la vectorización por periodo y el procesamiento en lotes con `reduceRegions` se documenta en el Anexo E, ítem E.2.b.

7.5 Fase 4: Métricas de fragmentación del paisaje (Julia)

Se computan métricas de ecología del paisaje sobre los parches de manglar vectorizados para cada uno de los tres periodos, aprovechando la velocidad de Julia en operaciones geométricas sobre grandes volúmenes de datos vectoriales. Las métricas incluyen: número de parches, densidad de parches por 1.000 hectareas, área media de parche con desviación estándar, índice de forma medio o Mean Shape Index ($MSI = \text{perímetro} / \sqrt{\pi \times \text{área}}$), distinto del MultiSpectral Instrument que comparte la sigla), distribución de parches por clases de tamaño (1–10, 10–50, 50–100, 100–500, 500–1.000 y 1.000–5.000 ha), y distancia media al vecino más cercano o Nearest Neighbor Distance (NND), como indicador de conectividad.

La función `compute_metrics` en Julia que calcula área (algoritmo del cordón), MSI y NND sobre los parches reproyectados a EPSG:9377 se documenta en el Anexo E, ítem E.4.a.

Tres patrones técnicos cierran la robustez del flujo: lectura perezosa de los rasters segmentados con `rasterio.open()` (que evitó el colapso del kernel observado con `vit_h` y motivó el cambio a `vit_b`), reproyección al sistema oficial colombiano EPSG:9377 con `geopandas.to_crs`, y aplicación de los predicados topológicos DE-9IM `intersects` y `contains` sobre los parches reproyectados para identificar truncamiento por frontera del AOI y envoltura del muestreo INVEMAR. El bloque articulado se documenta en el Anexo E, ítem E.2.a.

7.6 Forzamiento climático y validación local en R

El acoplamiento climático se valida con cuatro fuentes complementarias (ERA5-Land del ECMWF, índices ENSO ONI y SOI de la NOAA, caudal IDEAM-DHIME y precipitación CHIRPS) cruzadas con la anomalía NDVI z-score en rezagos de 0 a 3 meses, todas desagregadas por naturaleza espectral de las estaciones; los resultados se desarrollan en la sección **Forzamiento climático multifuente** y los bloques de código en el Anexo E, ítem E.3.a. Como contraparte local del flujo Python+GEE se construye además un cubo `stars` en R sobre los TIFs trimestrales Sentinel-2 ya descargados, cuya serie por estación reproduce la de `reduceRegions` en GEE con $\rho > 0,95$ y $RMSE < 0,05$ unidades NDVI (Anexo E, ítem E.1.c).

7.7 Fase 5: Validación con datos NASA y dashboard

Como componente de validación cruzada, se integran datos de la Global Flood Database, que registra 16 eventos de inundación históricos en la CGSM entre 2001 y 2017, y del JRC Global Surface Water, que identifica 977,4 km² de agua superficial permanente (ocurrencia > 50%) en el área de estudio,. Para el evento de septiembre 2020, se realiza una detección de inundación